


Projet : modélisation de pics de production de ressources

Yoan Thomas

Aya Ismahene Kroussa

Melvin Cerba

April 17, 2022



Contents

1	Élément historique	3
1.1	Modélisation des pics de productions	3
1.2	Courbe de Hubbert et sigmoïde	3
2	Algorithme d'approximation	5
2.1	Caractérisation	5
2.1.1	Critère	5
2.1.2	Gradient	5
2.1.3	Direction de descente	6
2.1.4	Figure des isocourbes avec les direction de descentes	6
2.1.5	Matrice de mise à l'échelle	6
2.1.6	Pseudo code	6
2.2	Test de contrôle de l'algorithme et des fonctions associées	6
2.2.1	Vérification du gradient par différences finies	6
2.2.2	Test de convergence avec données bruitées et non bruitées, en commençant plus ou moins loin de la solution	6
2.3	Performance <i>-optionnel</i>	6
2.3.1	Temps de convergence selon différent paramètre	7
3	Données réels	7
3.1	Vérification de la pertinence du modèle	7
3.1.1	Vérification de la pertinence du modèle sur plusieurs set de donnés <i>-optionnel</i>	7
3.1.2	Vérification de la pertinence sur la somme de la production mondiale <i>-optionnel</i>	7
3.1.3	Explication des lacunes du modèle	7
3.2	Pic de production <i>-optionnel</i>	7
3.2.1	Vérification de la performance de l'algorithme pour trouver les pics de production a posteriori	7
3.2.2	Performance de l'algorithme pour trouver les pics de production sur les données qui peuvent être modélisées par une sigmoïde	7
3.3	Amélioration de modèle	7
3.3.1	Deux sigmoïdes	7
3.3.2	n sigmoïdes	7
4	Conclusion	7

1 Élément historique



Peut-on prédire l'évolution de la production des ressources non renouvelables ? Pour tenter de répondre à cette question, nous proposons d'étudier à travers ce projet certains outils mathématiques qui permettent de modéliser la production des ressources non renouvelables. Plus spécifiquement, nous nous intéresserons à la production de pétrole.

1.1 Modélisation des pics de productions

Être capable de prédire l'évolution de la production de diverses ressources a toujours été un enjeu majeur, notamment en économie. Il est donc naturel que de nombreux modèles mathématiques promettant de modéliser cette évolution soient apparus. A travers ce projet, nous vous proposons d'étudier en détail l'un d'eux : la courbe de Hubbert.

En 1956, Marion King Hubbert présentait sa "courbe de Hubbert" à l'American Petroleum Institute. Son modèle, qui postule que la production croît, atteint un unique pic, puis décroît au même rythme qu'elle a augmenté en premier lieu, ne fit pas beaucoup parler de lui à l'époque. Mais lorsqu'en 1971, conformément à ses prédictions, la production pétrolière américaine atteignit son maximum et commença à décliner, ses travaux furent réexaminés avec beaucoup plus d'intérêt. Les chocs pétroliers de 1973 et 1979 semblèrent cependant définitivement invalider son modèle, qui perdit rapidement l'attention de l'industrie pétrolière.


Malgré tout, l'avènement du calcul informatique et la grande disponibilité de données poussèrent des auteurs modernes à exhumer le modèle de Hubbert et à l'étendre, notamment en donnant une formule mathématique à sa courbe, permettant ainsi de calculer son intégrale. C'est sur la base de ces nouveaux travaux que nous avons construit notre projet.



1.2 Courbe de Hubbert et sigmoïde

Les auteurs qui se sont approprié la courbe de Hubbert ont notamment travaillé à lui donner une expression mathématique. Ceci leur a permis de définir son intégrale, que nous appellerons "fonction sigmoïde" tout au long de ce rapport. Pour des raisons que nous expliciterons plus bas, cette dernière s'avère plus facile à manier que la courbe de Hubbert.

Une **courbe de Hubbert** est une fonction à 4 paramètres : a, b et τ , qui définissent sa forme ; et t , qui représente le temps. Par la suite, on notera indifféremment $Hubbert_{a,b,\tau}(t)$ ou $H_{a,b,\tau}(t)$.

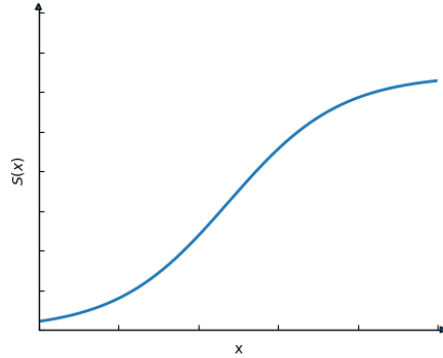


$$Hubbert_{a,b,\tau}(t) = \frac{\frac{ab}{\tau} e^{-\frac{t}{\tau}}}{(1 + be^{-\frac{t}{\tau}})^2} \quad (1)$$

Son intégrale, que nous appellerons **courbe sigmoïde**, est définie par :

$$Sigmoide_{a,b,\tau}(t) = \frac{a}{1 + be^{-t\tau}} \quad (2)$$

Posons $S_{max} = a$, $t_* = \tau \ln(b)$ et $\Theta = (S_{max}, t_*, \tau)$. On obtient :



$$Sigmoide_{\Theta}(t) = S_{max} \frac{1}{1 + e^{-\frac{(t-t_*)}{\tau}}} \quad (3)$$

Par la suite, on notera indifféremment $Sigmoide_{\Theta}(t)$, $Sig_{\Theta}(t)$ ou $Sig(t; \Theta)$.

Rappelons notre objectif et nos hypothèses : nous voulons modéliser la production de pétrole au cours du temps, et nous supposons que celle-ci atteint un unique pic. Il nous faudra donc déterminer le t pour lequel ce pic est atteint ainsi que la hauteur de ce pic (quantité de pétrole produit à l'instant t).




Figure 1: Une courbe de Hubbert et sa sigmoïde (Δ : pente de la sigmoïde au point d'inflexion t_*)

2 Algorithme d'approximation

Afin d'approximer les paramètres de la sigmoïde la plus en adéquation avec nos données, nous allons utiliser une méthode de minimisation de fonction réputée : la *descente de gradient*.

Conditions à vérifier

- *Initialisation* : pour que l'algorithme "descende" vers le minimum absolu de la fonction, il faut l'initialiser dans un "creux" qui le contienne, c'est à dire un intervalle sur lequel la fonction est convexe et dont l'image contient le minimum absolu de la fonction.
- *Direction de descente* : par ailleurs, il faut être certain que l'algorithme sache en tout instant dans quelle direction aller (ie. quelles modifications apporter aux paramètres) pour "descendre" vers le minimum. Pour cela, nous utiliserons le gradient.

Algorithme

L'algorithme fonctionne de la manière suivante :

1. Il calcule $\vec{\nabla} \text{Crit}_D(\text{Sig}(t; \Theta))$ le gradient de la fonction critère.
2. Il définit une direction de descente d à partir de $\text{vec} \nabla C$.
3. Il modifie les paramètres initiaux selon d et un pas δt .
4. Puis il recommence, jusqu'à satisfaire des conditions prédéfinies qui assure une certaine proximité au minimum de la fonction.

2.1 Caractérisation

Dans cette partie, nous

2.1.1 Critère

Avant toute chose, il nous faut une fonction à minimiser. Nous allons donc définir un *critère* qui évalue la distance qui sépare les données de la courbe du modèle. Plus précisément, nous additionnerons pour chaque année le carré de la différence entre l'estimation du modèle et les données réelles.

$$\text{Criterion}_{\text{Data}}(\text{Sig}(t; \Theta)) = \sum_{k=1}^N \delta t | \text{Data}(t_k) - \text{Sig}(t_k; \Theta) |^2 \quad (4)$$

avec :

$$\text{Data}(t_k) \text{ la somme des données de production de l'instant } t_1 \text{ à l'instant } t_k$$

$$\delta t$$

Par la suite, on notera indifféremment $\text{Criterion}_{\text{Data}}(\text{Sig}(t; \Theta))$, $\text{Crit}_D(\text{Sig}(t; \Theta))$ ou $\text{Crit}(\text{Sig}(t; \Theta))$.

2.1.2 Gradient

Afin de converger vers les paramètres optimaux, l'algorithme de la descente de gradient a besoin d'une direction de descente. Cela passe avant tout par le calcul du gradient de la fonction à minimiser, afin d'avoir une idée précise de l'évolution de cette dernière en fonction de chaque paramètre.

A partir de (4), on obtient :

$$\vec{\nabla} \text{Crit}(\text{Sig}(t; \Theta)) = \sum_{k=1}^N 2 * \vec{\nabla} \text{Sig}(t_k; \Theta) * (\text{Sig}(t_k; \Theta) - D(t_k)) \quad (5)$$

Il nous faut donc définir $\vec{\nabla} \text{Sig}(\Theta)$:

$$\vec{\nabla} \text{Sig}(t; \Theta) = \frac{\partial^2 \text{Sig}}{\partial t \partial \Theta}(t, \Theta) = \begin{bmatrix} \frac{\partial \text{Sig}}{\partial t \partial S_{\max}}(t, \Theta) \\ \frac{\partial \text{Sig}}{\partial t \partial t_*}(t, \Theta) \\ \frac{\partial \text{Sig}}{\partial t \partial \tau}(t, \Theta) \end{bmatrix}$$

Par le calcul, on obtient :

$$\vec{\nabla} Sig(t; \Theta) = \begin{bmatrix} \frac{1}{1+e^{-\frac{(t-t_*)}{\tau}}} \\ \frac{-S_{max}}{\tau} * \frac{e^{-\frac{(t-t_*)}{\tau}}}{(1+e^{-\frac{(t-t_*)}{\tau}})^2} \\ \frac{-S_{max}}{\tau^2} * \frac{e^{-\frac{(t-t_*)}{\tau}} * (t-t_*)}{(1+e^{-\frac{(t-t_*)}{\tau}})^2} \end{bmatrix} \quad (6)$$

Nous sommes donc capables de calculer le gradient de la sigmoïde pour des paramètres S_{max} , t_* et τ donnés. Mais comment en tirer une direction de descente ?

2.1.3 Direction de descente

Le gradient nous d

2.1.4 Figure des isocourbes avec les direction de descentes

Affichage de figure, et justification de la nécessité de l'utilisation d'une matrice de mise à l'échelle

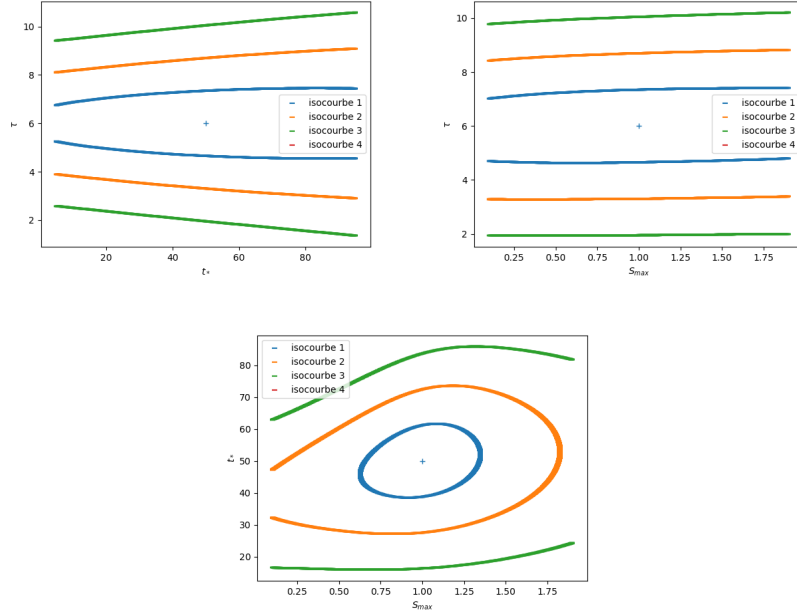


Figure 2: Une courbe de Hubbert et sa sigmoïde (Δ : pente de la sigmoïde au point d'inflexion t_*)

2.1.5 Matrice de mise à l'échelle

Définition de la matrice de mise à l'échelle

2.1.6 Pseudo code

Pseudo code

2.2 Test de contrôle de l'algorithme et des fonctions associées

Avant de lancer la l'algorithme sur des données réelles on vérifie que nos fonctions soient justes et que l'algorithme converge pour des données simulées

2.2.1 Vérification du gradient par différences finies

Test rapide du gradient par la méthode des différences finies

2.2.2 Test de convergence avec données bruitées et non bruitées, en commençant plus ou moins loin de la solution

Test rapide de convergence l'algorithme sur des données générées, il y aura 4 tests comme précisé dans le titre se la sous-section

2.3 Performance -optionnel

Test des performances de l'algorithme

2.3.1 Temps de convergence selon différent paramètre

Différents tests sur la vitesse de convergence sur par exemple : le niveau de bruit, la distance entre le point de départ et la solution, le facteur de rebroussement, etc

3 Données réels

Après l'introduction de l'algorithme, introduction de l'algorithme aux données réelles et évaluation des ces performances

3.1 Vérification de la pertinence du modèle

Application de l'algorithme sur un jeu de données pertinentes

3.1.1 Vérification de la pertinence du modèle sur plusieurs set de donnés -optionnel

Généralisation du test de pertinence

3.1.2 Vérification de la pertinence sur la somme de la production mondiale -optionnel

Test de la pertinence du modèle sur une vue globale

3.1.3 Explication des lacunes du modèle

Après avoir mit en exergue les lacunes sur quelques jeux de données, tentatives de caractérisations des hypothèses de validité du modèle

3.2 Pic de production -optionnel

Vérification de la performance de l'algorithme pour trouver les pics de production

3.2.1 Vérification de la performance de l'algorithme pour trouver les pics de production a posteriori

La détermination du pics étant simple a posteriori, on peut calculer de la performance de l'algorithme à trouver le pic de production a posteriori

3.2.2 Performance de l'algorithme pour trouver les pics de production sur les données qui peuvent être modélisées par une sigmoïde

En prenant des sets de données qui peuvent être convenablement modélisé par une sigmoïde, on peut cherche à quel point le modèle est prédictif. Pour cela on calcul la précision avec laquelle l'algorithme prédit le pic de production en se limitant aux premières données jusqu'à un temps t

3.3 Amélioration de modèle

Avec un algorithme flexible, on peut essayer d'améliorer la modélisation

3.3.1 Deux sigmoïdes

Si il y a deux pics, est-ce que deux sigmoïdes additionnées est un bonne modélisation?

3.3.2 n sigmoïdes

Si il y a n pics, est-ce que n sigmoïdes additionnées est un bonne modélisation?

4 Conclusion